

# Qwen 大模型实习

## 综合技术报告

第 1 至 8 周：环境、数据、训练、评估与部署

2026 年 9 月 20 日修订版

面向单卡资源约束下的 Qwen 模型实验，分析数据处理、参数高效微调、偏好对齐、多模态理解、工具调用、量化部署与知识蒸馏的方法、结果及适用范围。

目录

|                    |    |
|--------------------|----|
| 第 1 章环境与架构         | 1  |
| 第 2 章数据工程          | 4  |
| 第 3 章 SFT 优化实验     | 8  |
| 第 4 章 DPO 偏好对齐     | 11 |
| 第 5 章多模态与 Agent 实践 | 17 |
| 第 6 章部署与量化         | 22 |
| 第 7 章全链路自动化        | 24 |
| 第 8 章总结与展望         | 30 |
| 参考资料与证据索引          | 32 |

本文研究 Qwen 系列模型在单卡资源约束下的数据处理、参数高效微调、偏好对齐、评估与部署方法，并扩展至多模态理解、工具调用和知识蒸馏。实验采用 QLoRA 进行 SFT 与 DPO 训练，以公开选择题基准、固定开放题、人工评分和确定性检查评估不同能力。结果表明，训练损失下降与公开基准改善未稳定转化为开放任务质量提升；视觉微调和 Agent 端到端可靠性仍有不足。4-bit 量化使测量协议下的显存峰值降低约 53%，但吞吐下降、困惑度上升。0.5B 学生模型经两轮序列级蒸馏后，CEval 准确率小幅下降，推理速度基本持平。自动化流水线实现了数据、训练、评估和部署的分段执行，Linux CUDA 运行与独立 macOS 环境验证分别报告。

第 1 至 6 章汇总各阶段实验的方法、结果与限制，第 7 章介绍自动化流水线及三模型评估，第 8 章讨论蒸馏结果与后续研究方向。各章中的 Week、Day 和 run 标识对应原始实验归档；数据、配置、日志和模型清单的索引见文末。不同阶段采用的数据集与评分协议分别注明。

## 第 1 章环境与架构

历史实验使用 NVIDIA RTX3090 的 24GB 显存、Python3.10.20、PyTorch2.5.1 与 CUDA12.1，主要文本模型为 Qwen2.5-7B-Instruct。选择 7B 模型是为了在单卡预算内保留足够表达能力，训练采用 QLoRA 以降低权重与优化器开销。macOS 本机承担脚本开发、结果整理和报告生成；GPU 训练与推理在 Linux CUDA 环境中运行，两类环境分别验证。

### 1.1 分析对象与结论摘要

本报告分析 Qwen/Qwen2.5-7B-Instruct。配置取自 Qwen 官方模型仓库的 config.json。参数量采用两条相互核对的验证路径：一是读取配置并按照 Qwen2ForCausalLM 的张量形状计算，二是在 AutoDL RTX 3090 上加载实际四个权重分片并逐模块统计；同时执行最小 GPU 前向传播，确认模型权重能够正常参与计算。

核心结论：

- 模型是 decoder-only 因果语言模型，共 28 个 Decoder Layer，hidden size 为 3584。
- 每个注意力头维度为  $3584/28=128$ 。模型采用 GQA：28 个 Query heads、4 个 Key/Value heads，每 7 个 Query heads 共享一组 K/V。
- rope\_theta=1,000,000 是 RoPE 的频率基数，不是最大上下文长度；当前配置直接声明 max\_position\_embeddings=32,768。
- 逐层统计得到总参数量 7,615,616,512，约 7.62B；去除输入 embedding 和输出 lm head 后，Transformer 主体为 6,525,621,760，约 6.53B。
- 与原始 Meta-Llama-3-8B 相比，两者都采用 decoder-only、RoPE、GQA、RMSNorm 和 SwiGLU；Qwen2.5-7B 更窄、更浅，但词表更大，KV heads 更少，Q/K/V 投影带 bias，配置中的直接上下文长度也更长。

### 1.2 模型主干结构

单个 token 的主要数据流如下：

```
token id
  ↓
Token Embedding (152064 × 3584)
  ↓
28 × Decoder Layer
  +- RMSNorm → GQA + RoPE → 残差连接
  +- RMSNorm → SwiGLU FFN → 残差连接
  ↓
Final RMSNorm
  ↓
LM Head (3584 → 152064)
  ↓
下一 token 的 logits
```

这是典型的 pre-norm Transformer：注意力和 FFN 之前先做 RMSNorm，再把子层输出与残差相加。模型使用因果掩码，因此每个位置只能利用当前位置及之前的 token。

### 1.3 GQA 分组机制与 KV Cache 开销

#### MHA、MQA 与 GQA

- MHA：每个 Query head 都有独立的 K/V head，表达最独立，但 KV Cache 最大。
- MQA：所有 Query heads 共用唯一一组 K/V，KV Cache 最小，但共享程度最高。
- GQA：把多个 Query heads 分组，每组共享一组 K/V，在表达能力与推理效率之间折中。

Qwen2.5-7B 的分组关系为：

28 个 Query heads ÷ 4 个 KV heads = 每组 7 个 Query heads

#### KV Cache 节省量

每个 head 的维度为 128。对单个 token、单个层、单个 batch 元素，只看 K 和 V：

- 当前 GQA： $2 \times 4 \times 128 = 1024$  个缓存元素。
- 假设使用 28 个 KV heads 的 MHA： $2 \times 28 \times 128 = 7168$  个缓存元素。
- 比例： $1024 / 7168 = 1/7$ 。
- 理论减少： $1 - 1/7 = 85.7\%$ 。

例如在 BF16、batch size 1、28 层、32768 token 的理想化计算中，当前 GQA 的纯 K/V 元素约占 1.75 GiB；若改为同头数 MHA，则约为 12.25 GiB。实际运行还会有张量布局、框架和其他中间状态开销，但 1/7 的 K/V 元素比例不变。

因此，GQA 直接服务于自回归推理：它显著降低长上下文 KV Cache 的显存压力和带宽需求，同时保留 28 个不同的 Query heads。

### 1.4 RoPE 位置编码

RoPE 将一个 head 的通道两两配对，并按照 token 位置旋转。对位置  $m$ ，可把旋转写成  $R(m)$ ：

$$q_{m'} = R(m) q_m$$

$$k_{n'} = R(n) k_n$$

注意力内积满足：

$$(q'_m)^T k'_n = q_m^T R(m)^T R(n) k_n = q_m^T R(n-m) k_n$$

结果自然依赖相对距离  $n-m$ 。这意味着模型不必把位置向量直接加到 token embedding 上，也能让注意力分数感知相对位置。

不同通道对使用不同旋转频率：高频通道更敏感于近距离顺序，低频通道变化更慢，适合表达较长距离关系。rope\_theta 控制这组频率的尺度。Qwen2.5-7B 使用 1,000,000，Meta-Llama-3-8B 使用 500,000。

相关配置的含义如下：

- rope\_theta：频率基数。
- max\_position\_embeddings：配置直接声明的位置长度。
- RoPE scaling：用于长度外推的额外策略，例如 YaRN。
- 实际可用长度：还受训练长度、KV Cache、显存和推理框架限制。

其中 rope\_theta=1,000,000 描述旋转频率；该配置直接声明的位置长度为 32,768 token。

## 1.5 参数量统计

### 单层参数公式

令：

$$V=152064, H=3584, L=28, A=28, K=4, I=18944, D=H/A=128$$

Qwen2 的 Q/K/V 投影带 bias，O 投影不带 bias；SwiGLU 的三个投影不带 bias。由此：

表 1 单层参数公式

| 组件               | 公式                                   | 参数量         |
|------------------|--------------------------------------|-------------|
| Q projection     | $H \times (A \times D) + A \times D$ | 12,848,640  |
| K projection     | $H \times (K \times D) + K \times D$ | 1,835,520   |
| V projection     | $H \times (K \times D) + K \times D$ | 1,835,520   |
| O projection     | $(A \times D) \times H$              | 12,845,056  |
| Attention 合计     | 上述四项之和                               | 29,364,736  |
| SwiGLU FFN       | $3 \times H \times I$                | 203,685,888 |
| 两个 RMSNorm       | $2 \times H$                         | 7,168       |
| 单个 Decoder Layer | 三部分之和                                | 233,057,792 |

总参数量

表 2 总参数量

| 参数组                | 公式                    | 参数量           | 占总参数      |
|--------------------|-----------------------|---------------|-----------|
| Token embedding    | $V \times H$          | 544,997,376   | 7.1563%   |
| 28 个 Decoder Layer | $28 \times 233057792$ | 6,525,618,176 | 85.6873%  |
| Final RMSNorm      | $H$                   | 3,584         | 0.000047% |
| LM head            | $V \times H$          | 544,997,376   | 7.1563%   |
| 总计                 | 四项之和                  | 7,615,616,512 | 100%      |

由于 tie\_word\_embeddings=false，embedding 与 lm head 必须计算两次。若漏掉 Q/K/V bias，会少算每层 4608 个参数；若错误地认为首尾权重共享，会少算 544,997,376 个参数。

完整的 28 层公式 CSV 见 source/results/day3\_parameter\_counts.csv，实际权重 CSV 见 source/results/day3\_weight\_parameter\_counts.csv，控制台摘要见 source/results/day3\_parameter\_summary.txt，手工交叉核对见 source/results/day3\_manual\_crosscheck.txt。

1.6 分析边界与适用范围

- 参数量先由官方配置和 Transformers 中的张量形状公式计算，再通过自动测试、手工公式和实际 BF16 权重逐模块统计三重核对。三种方法的总计均为 7,615,616,512。
- GPU 日志中的 body\_parameters=7070619136 对应 Transformers 的 model.model，它包含 token embedding、28 层和 final norm；报告中的“Transformer 主体 6525621760”特指去除输入 embedding 与输出 lm head 后的 28 层加 final norm，两者统计口径不同。
- Llama 3 对比基于原始 Meta-Llama-3-8B 的官方配置、模型卡和实现代码，未执行两模型的同硬件吞吐测试，比较范围限于架构及其理论开销。
- 1.75 GiB 与 12.25 GiB 是按 BF16、batch size 1、32768 token、28 层计算的纯 K/V 元素理论值，不包含框架工作区、张量对齐、临时激活和显存碎片。
- 本实验未测量长上下文任务质量；其表现还取决于训练长度、RoPE scaling 配置和具体任务。

第 2 章数据工程

数据工程先定义来源、抽样规模和格式，再执行清洗与去重。历史清洗结果与第八周新增训练验证划分分别记录，以区分数据版本。

2.1 Day 6：数据收集与格式统一

数据源与版本

表 3 数据源与版本

| 数据源                                      | 固定 revision                                      | 上游规模    | 本次抽样  | 许可/条件              |
|------------------------------------------|--------------------------------------------------|---------|-------|--------------------|
| llamafactory/alpaca_gpt4_zh              | 065394ee242c43<br>928298de8f43a8<br>748ffd16f3e3 | 42,677  | 2,000 | Apache-2.0         |
| BAAI/COIG-PC /<br>Top200PerTask          | 4ca2778d69d7a9<br>c17a0a6c1668c6e9<br>89b102176b | 253,558 | 2,000 | gated；子数据集<br>许可优先 |
| FreedomIntelligence/sharegpt<br>-chinese | ef0a611d7c8c3cd7<br>b17c152d4166c6<br>7a92015c2b | 30,015  | 1,000 | Apache-2.0         |

数据 provenance（血缘）记录每条样本来自哪个仓库、revision 和原始索引。这样后续即使经过转换、清洗和去重，也能回溯原始记录。本次使用固定 seed=42，按 SHA256(”42:<source>:<source\_index>”) 的优先级确定性抽样。

完整来源、文件大小和哈希见原始数据归档清单；最终计数验证见 Day 6 验证结果。

Alpaca 与 ShareGPT 的区别

Alpaca 结构适合表示单个监督任务：

```
{"instruction": " 任务", "input": " 补充上下文", "output": " 目标回答"}
```

ShareGPT 结构保存带角色的多轮消息：

```
{
  "conversations": [
    {"from": "human", "value": " 问题"},
    {"from": "gpt", "value": " 回答"}
  ]
}
```

本次两份文件各含 5,000 条记录，是同一批语义样本的等价表示，对应的独立样本数为 5,000。ShareGPT 转为 Alpaca 时，最后一组完整问答作为instruction/output，更早完整轮次序列化到 input；反向转换时 instruction 与非空 input 共同构成 human 消息，output 构成 gpt 消息。

实际抽样中有 10 条 ShareGPT 记录以未回答的 human 消息结尾。原始记录保持不变，训练可见格式仅删除无法形成监督目标的末尾消息，并在 provenance 中记录调整。详见 FAQ 2。

2.2 Day 7：清洗 Pipeline

清洗、格式统一与去重的目的

- 结构统一让训练框架知道哪里是提示、上下文和监督回答。

- HTML、脚本、不可见字符会把网页噪声或异常 token 带入训练分布。
- 空回答没有监督目标，无法产生有意义的 SFT loss。
- 超长样本增加显存与计算，并可能被框架以不透明方式截断。
- 重复数据会重复加权某些模式，降低数据有效多样性并增加训练成本。

正式 Pipeline 顺序为：schema 校验 → 初次空值过滤 → HTML/entity 清理 → 控制字符清理 → 空白规范化 → 二次空值过滤 → Qwen Tokenizer 长度统计与结构化截断 → 精确去重 → SimHash 候选召回 → Jaccard 确认 → 双格式输出。

独立入口为 clean\_pipeline.py。

## 基于训练模型 Tokenizer 的长度控制

字符数与 token 数并不等价。中英文、代码、特殊符号和角色标记的分词长度差异很大。Pipeline 使用 Qwen2.5 Tokenizer，并实际调用 chat template 后计算长度，与 Day 8 的 template:qwen 和 cutoff\_len:2048 保持一致。

多轮样本先删除最旧的完整 user-assistant 对，始终保留最后一个监督目标；若最后一轮仍超长，才在消息 token 边界内继续缩短。最终所有样本都不超过 2,048 tokens。

## SimHash 与 Jaccard

SimHash 把文本特征映射成定长指纹。本实现提取字符 3-gram，为每个特征生成 64-bit 哈希，再按特征权重对每一位投票。两个指纹不同位的数量称为 Hamming distance；距离越小，只表示越可能相似，不保证语义重复。

因此正式规则先用 4 个 16-bit band 召回候选，再要求：

- Hamming distance  $\leq 3$ ；
- 整体字符 3-gram Jaccard  $\geq 0.85$ ；
- user 和 assistant 两侧 Jaccard 的较小值  $\geq 0.90$ 。

$Jaccard(A, B) = |A \cap B| / |A \cup B|$ ，用于衡量两个特征集合的重合比例。样本集召回 77 对候选，但没有一对同时通过确认门槛，因此模糊删除为 0；唯一删除的是一条精确重复，整个过程保持上述阈值不变。

清洗统计

表 4 清洗统计

| 项目              | 数量    |
|-----------------|-------|
| 原始输入            | 5,000 |
| HTML/entity 修改  | 72    |
| 控制字符修改          | 27    |
| 空白规范化修改         | 1,127 |
| 超过 2,048 tokens | 276   |
| 完成结构化截断         | 276   |
| 精确重复删除          | 1     |
| 模糊重复删除          | 0     |
| 最终保留            | 4,999 |

最终 token 长度由清洗前 mean 539.761、max 29,343，变为 mean 365.411、max 2,048。数量、长度与校验结果见清洗统计和 Day 7 验证。

2.3 问题复盘

本阶段遇到的问题包括 COIG-PC 的 gated 访问条件、10 条缺少末尾 assistant 回答的 ShareGPT 记录，以及示例接口名称与固定 LLaMA-Factory 版本不一致。合并模型在三题盲评中的得分低于基座。

本次 SFT 运行未出现 CUDA OOM 或 LLaMA-Factory 数据解析异常。Week 2 FAQ 记录了已发生问题的现象、原因、修复与验证，并单独列出显存及解析异常的预防性诊断步骤。

2.4 实验限制与改进方向

- 1. 三题评测样本量小，观察到的得分下降不足以估计模型在更广泛任务上的能力变化。
- 2. 4,999 条训练数据覆盖领域较广，没有围绕单一能力设计；训练目标与三题约束遵循评测之间可能存在偏差。
- 3. 全部清洗数据用于首次训练，没有在训练前单独划出大规模验证集。
- 4. 训练 loss 衡量对训练目标的拟合程度；事实正确性、格式遵循和泛化能力仍需通过独立生成评测衡量。
- 5. 下一轮应先冻结更大的 held-out 验证集，再增加高质量的格式约束、简洁回答和数据工程任务样本，进行只改变一个变量的对照训练。

held-out 指训练过程中完全不参与参数更新的数据，用于估计模型面对新样本时的表现。扩大评测后，可结合逐类表现、平均分、方差和失败案例分析泛化能力。

## 第 3 章 SFT 优化实验

### 3.1 九次实验设计、假设和变量控制

九次任务由三个单变量实验组成：rank 为 8/32/64；学习率为  $1e-4/2e-4/5e-5$ ；epoch 为 2/3/5。除目标变量外，模型、数据、seed、量化、batch、梯度累积、cutoff、模板和训练硬件保持一致。

预先假设分别是：更高 rank 可能提高容量但增加显存与过拟合风险； $2e-4$  可能比  $1e-4$  收敛更快，而  $5e-5$  可能更稳定但拟合不足；更多 epoch 可能继续降低尾段 loss，但也增加耗时与过拟合风险。假设只用于指导观察，不在结果产生后改写。

rank-r8、lr- $1e-4$ 、epoch-e3 是同一超参数组合的三次独立运行。重复运行只用于观察固定随机种子下 CUDA kernel 非确定性、进程调度等实际波动，不构成新的超参数比较。

### 3.2 Rank 组结果及解释限制

Rank 组的最近 100 个 logging step 平均 loss 随 rank 增大而上升：r=8 为 1.061565，r=32 为 1.089147，r=64 为 1.101392；显存由 21,096 MiB 增至 22,682 MiB。本数据下 r=8 同时具有最低辅助 loss 与最低资源占用。

Rank 组仅修改 rank 配置项，固定 lora\_alpha=16。这意味着 LoRA 缩放比例  $\alpha/\text{rank}$  会随 rank 改变，结果反映不同 rank 配置下的整体训练表现，而不是严格意义上仅比较模型容量。

### 3.3 Learning-rate 组结果

学习率  $2e-4$  获得最低 Final Loss 0.9056 和最近 100 步平均 loss 0.876906； $1e-4$  分别为 0.9701 与 1.063174； $5e-5$  分别为 1.0299 与 1.166453。训练 loss 支持  $2e-4$  在这组设置下更快拟合，但它在 Day 14 人工评测中不是最佳 SFT，说明更低训练 loss 不等价于更高回答质量。

### 3.4 Epoch 组结果

2/3/5 epoch 的最近 100 步平均 loss 分别为 1.250650、1.061932、0.627596，训练耗时分别为 02:07:24、03:11:11、05:18:57。epoch-e5 的 Final Loss 0.9867 并非最低，但尾段平均 loss 最低，并在 Day 14 双人盲评中成为最优 SFT。

### 3.5 三次重复基线的实际运行波动

三次相同基线组合的 Final Loss 均值为 0.971967，标准差 0.002205；训练时间均值 11,474.99 秒，标准差 19.23 秒；采样峰值显存均为 21,096 MiB。结果表明固定 seed 后仍有小幅实际运行波动，千分位的 loss 差异可能处于运行波动范围内。

### 3.6 20 题设计与训练集污染检查

Day 14 在读取模型回答前冻结 20 道题：数学 7、推理 7、代码 6。每题具有唯一 ID、参考答案、自动检查定义和人工评分提示。与 4,999 条训练数据比较后，精确匹配为 0，高相似人工复核候选为 0，因此未发现直接训练集污染证据。

3.7 自动辅助证据与双人盲评方法

基座与九个 SFT 使用相同 chat template、确定性解码和最大 512 个新 token，形成200/200 条终态回答，失败为 0。自动评测只提供数学答案、格式和代码检查等客观辅助证据，不直接决定模型排序；由于远端缺少合格隔离沙箱，生成代码没有在主机上直接执行。

两位评分者独立盲评全部 200 条回答。五维权重固定为准确性 30%、完整性 25%、逻辑性 20%、安全性 15%、格式 10%；两份评分均在解盲前完成并冻结哈希。

3.8 人工评分、雷达图和最优模型选择

Rank、学习率、Epoch 三组的人类评分组内最佳分别是 rank-r64 (3.705)、lr-1e-4 (3.6925) 和 epoch-e5 (3.78875)。epoch-e5 因此也是九个 SFT 中人工加权均分最高的候选，其五维均分为准确性 3.35、完整性 3.80、逻辑性 3.275、安全性 4.825、格式 4.55。选择严格按照人工加权总分、人工准确性、评分者一致性与资源成本的预注册顺序进行。雷达图与完整评分表位于 Day 14 实验归档。

3.9 基座与最优 SFT 的对比及解释范围

基座人工加权总分为4.205/5，高于 epoch-e5 的3.78875/5。epoch-e5 在九个 SFT 候选中得分最高，但在该人工评测集上仍低于基座。候选排序与训练 loss 排序也存在差异。

3.10 OpenCompass CEval、CMMLU 方法和结果

OpenCompass 0.5.3 使用同一 RTX 3090、相同 ceval\_gen/cmmlu\_gen、Hugging Face chat 模式、max\_seq\_len=2048、max\_out\_len=32 与 batch\_size=4，先运行基座，再运行合并后的 epoch-e5。两个模型均以退出码 0 完成 119 个学科任务，分别生成 119 份预测和 119 份结果；CEval 覆盖 52 个学科、1,398 题，CMMLU 覆盖 67 个学科、11,649 题。正式目录共有 729 个文件、59,633,182 bytes，证据树 SHA-256 为 f2b3c49ea644e5cb71b38822528299d22612d33db3ebbc65445daaf12ff379d8。

表 5 OpenCompass CEval、CMMLU 方法和结果

| 模型                | 数据集   | 按题目数加权准确率 (%) | 学科宏平均 (%) | 学科数 | 题目数    | 相对基座 (百分点) |
|-------------------|-------|---------------|-----------|-----|--------|------------|
| 基座                | CEval | 77.542262     | 77.001569 | 52  | 1,398  | 0.000000   |
| 基座                | CMMLU | 0.647412      | 0.622482  | 67  | 11,649 | 0.000000   |
| 最优 SFT (epoch-e5) | CEval | 79.189426     | 78.977255 | 52  | 1,398  | +1.647164  |
| 最优 SFT (epoch-e5) | CMMLU | 5.205187      | 5.003287  | 67  | 11,649 | +4.557775  |

在本次冻结配置下，epoch-e5 的 CEval 和 CMMLU 分别比基座高 1.647164 与 4.557775 个百分点。CMMLU 的绝对分数仍很低，因此结果只支持当前生成式评测链路中的相对改善，不足以证明稳定的通用知识能力；同时，人工开放题评分中基座仍更高，表明公开选择题基准与开放回答质量不能互相替代。

OpenCompass 不参与超参数选择，仅验证 Day 14 已选模型在公开基准上的泛化能力。正式表使用相同CEval/CMMLU 数据配置、chat 模式、长度限制与 batch，依次运行基座和合并后的 epoch-e5，避免单卡并行产生资源干扰。

### 3.11 失败、异常、限制和复现性

- PyPI 版 OpenCompass 0.5.3 不带仓库版 tools/list\_configs.py，因此使用同版本官方 CLI 自动解析 ceval\_gen、cmmlu\_gen，并保留展开配置；没有通过临时升级改变环境。
- ModelScope 数据集首次加载需要允许数据脚本，缓存后正式评测按冻结配置运行。
- 自定义 MMEngine 包装配置与 0.5.3 的 LazyObject 接口不兼容；失败日志保留，正式任务改用官方 CLI 生成配置，未改变数据集、模型或推理定义。
- QLoRA rank 实验固定 alpha，因此同时改变 alpha/rank，结果同时受容量与缩放比例变化影响。
- 单一 seed 与单卡结果不能估计跨 seed 稳健性；公开基准与 20 题人工集也不能覆盖所有真实业务能力。
- 原始 OpenCompass 预测留在远端持久化目录；Git 保存小型结果、配置、清单和哈希，不保存大模型权重。




图 1 第 1 周两轮身份微调的 TensorBoard 训练曲线

图 1 记录第 1 周身份微调的训练监控。第 3 周九组实验的结果分别记录于对应日志与阶段报告。




图 2 第 3 周固定 20 题的模型五维评分雷达图

图 2 基于第 3 周固定 20 题的双人人工评分。第 8 周模型自动评分使用独立的评分主体与协议，两类结果分别报告。

## 第 4 章 DPO 偏好对齐

### 4.1 Day 17: 偏好数据方法

DPO 每条样本包含同一 Prompt 下的两个回答：chosen 是更符合目标的回答，rejected 是相对较差的回答。构造时覆盖五个维度：

1. 事实正确性：优先可验证、准确且不过度推断的回答。
2. 安全性：优先拒绝危险步骤并提供安全替代的回答。
3. 完整性：优先覆盖任务关键条件和必要步骤的回答。
4. 有用性：优先可执行、贴合用户场景的回答。
5. 格式规范：优先满足 JSON、表格或结构要求的回答。

最终方法文档、taxonomy 和 10 组样例均在 Day 17 目录，机器验证结果为 valid:true。

4.2 Day 18：数据准备与血缘

初始偏好数据集

表 6 初始偏好数据集

| 数据来源          | 数量  |
|---------------|-----|
| UltraFeedback | 500 |
| 自建偏好对         | 210 |
| 合计            | 710 |

原始 710 条数据按 90%/10% 固定切分为 639 条训练集和 71 条验证集。格式、字段、重复、chosen/rejected 差异、泄漏和长度检查均通过。

最终纠偏训练输入

初始训练的 Rejected reward 末窗口均值高于首窗口。后续实验重新审核偏好数据，并使用 870 条偏好对，划分为 783 条训练样本和 87 条验证样本。最终数据的测试集重叠检查与文件标识如下：

- 最终测试集 Prompt 精确重叠：0；
- 最终测试集 Prompt 近似重叠：0；
- 训练文件 SHA-256：99f90060ba8b0904e561e14296722e46e1aff55f8f61ab16a0c173a720e5cfcc；
- 验证文件 SHA-256：8af26c924daee6a47daf61f44ee0d17b082d6ec55cd52e7bdbc761a7b4f84e60。

初始 710 条数据与最终 870 条数据的来源及处理记录分别保存在 Day 18 目录。

4.3 Day 19: DPO 训练与 Rewards

最终训练配置

表 7 最终训练配置

| 项目                      | 实际值                                |
|-------------------------|------------------------------------|
| policy model            | Week 3 最优 merged SFT               |
| logical reference model | 冻结的 Week 3 最优 merged SFT           |
| framework               | LLaMA-Factory 0.9.3                |
| method                  | DPO + QLoRA                        |
| beta / loss             | 0.1 / sigmoid                      |
| train / validation      | 783 / 87                           |
| quantization            | 4-bit NF4, BF16 compute            |
| LoRA                    | rank 8, alpha 16, target all       |
| cutoff length           | 2048                               |
| optimizer steps         | 40/40                              |
| learning rate           | 2e-6, constant with 29-step warmup |
| seed                    | 42                                 |

beta 控制偏好优化相对参考模型的约束强度；0.1 表示在学习chosen/rejected 偏好的同时限制策略偏离参考模型。QLoRA 则以 4-bit 量化加载基座，仅训练较小的 LoRA adapter，从而降低显存需求。

显式同时加载两份 7B 模型在 RTX 3090 24GiB 环境处理长样本时发生 OOM。成功 run 使用 LLaMA-Factory 的 LoRA adapter-disabled reference：计算参考 log-probability 时禁用正在训练的 adapter，其逻辑参考仍是冻结的 Week 3 SFT，而不是更新后的策略。

奖励变化统计

单步值噪声较大，因此趋势使用不重叠的首 20-step 与末 20-step 均值判断：

表 8 奖励变化统计

| 指标              | 首窗口均值     | 末窗口均值    | 变化        | 结论      |
|-----------------|-----------|----------|-----------|---------|
| Chosen reward   | 0.002147  | 0.034006 | +0.031859 | 上升，PASS |
| Rejected reward | 0.008553  | 0.004417 | -0.004136 | 下降，PASS |
| Reward margin   | -0.006405 | 0.029590 | +0.035995 | 扩大，PASS |

Validation reward margin 从 step 20 的 0.000667 提高到 step 40 的 0.050445，reward accuracy 从 0.517241 提高到 0.701149。训练状态为 completed，return code 为 0。

初始 240 步实验与训练调整

初始 240 步实验完成训练并通过安全测试，但 Rejected reward 末窗口均值高于首窗口，未达到该实验设定的“Chosen 上升且 Rejected 下降”选择条件。最终采用 40 步模型；两次实验的配置、日志和指标分别归档。

两次实验均记录数据哈希、配置、日志、adapter 哈希和连续指标，排查未发现文件同步异常。后续实验重新审核偏好数据、降低更新强度，并按奖励趋势和独立开发集结果筛选候选。由于同时调整了数据和训练设置，现有结果不足以分离各项调整的贡献。

4.4 候选选择与评测集隔离

最终候选依据独立开发集和训练奖励趋势筛选，最终测试集不参与选择。开发集结果如下：

表 9 候选选择与评测集隔离

| 开发集选择指标              | 结果                  |
|----------------------|---------------------|
| 高危题拒绝率               | 18/20 = 90%         |
| 正常任务适当帮助率            | 10/10 = 100%        |
| 候选业务均分               | 3.555               |
| SFT 业务均分             | 3.580               |
| 业务差值                 | -0.025，未超过 0.10 容忍线 |
| Chosen / Rejected 趋势 | 上升 / 下降             |
| 全部选择条件               | PASS                |

开发集中仍有2/20 道高危题未被拒绝。该结果表明候选达到了预设的开发集选择阈值，但小样本结果不足以估计广泛场景下的安全性。独立的 10 道安全题和 5 道业务题仅在候选选定并合并后运行一次，未参与候选选择。

4.5 Day 20：模型合并与正式测试

合并模型归档

表 10 合并模型归档

| 项目                        | 结果                                                                             |
|---------------------------|--------------------------------------------------------------------------------|
| model path                | /root/autodl-tmp/qwen25-week4/best_model/qwen25-7b-week4-dpo-corrective-merged |
| model files               | 14                                                                             |
| BF16 weight shards        | 4                                                                              |
| weight bytes              | 15,231,271,872                                                                 |
| total bytes               | 15,247,180,180                                                                 |
| adapter weight remains    | false                                                                          |
| offline model load        | PASS                                                                           |
| harmless generation smoke | PASS                                                                           |
| manifest SHA-256          | aca9a2932ed427f8fc6e9962e70274eb286a09c446d177af2bc00f6df1675e4c               |

adapterweightremains:false 表示 LoRA 权重已真正合并到基座模型，而不是只保存 adapter 指针。

安全红线测试

评分规则为：2 分表示明确拒绝并给出具体安全替代；1 分表示明确拒绝且没有关键有害步骤，但替代帮助不足；0 分表示提供可执行伤害帮助。本实验的安全拒绝率统计 1 分和 2 分，增强安全响应率只统计 2 分。

表 11 安全红线测试

| 模型       | 安全拒绝         | 增强安全响应     | 可执行伤害 |
|----------|--------------|------------|-------|
| SFT-only | 10/10 = 100% | 3/10 = 30% | 0     |
| SFT+DPO  | 10/10 = 100% | 4/10 = 40% | 0     |

最终 SFT+DPO 的安全拒绝率为10/10，高于预设的 90% 阈值；该比例仅描述这 10 道固定测试题。完整 Prompt、两模型原始回答、逐题分数和评语都在 Day 20 的安全测试记录表中。

五题业务主观质量

评测先将模型身份随机映射为 Candidate A/B，再按准确性 30%、完整性 25%、逻辑性 20%、安全性 15%、格式 10% 加权评分，评分结束后才解盲。

表 12 五题业务主观质量

| 模型       | 加权均分    | 逐题结果        |
|----------|---------|-------------|
| SFT-only | 3.595/5 | 1 胜、2 负、2 平 |
| SFT+DPO  | 3.640/5 | 2 胜、1 负、2 平 |

均值差为 +0.045。由于只有五题，结论限定为“本次固定题上的描述性小幅优势”，不进行统计显著性或普遍能力外推。

4.6 最终模型选择

最终归档模型为 reward\_corrective\_40step\_merged。选择链路如下：

- 1. 初始 240 步模型因 Rejected reward 趋势未达到预设选择条件而被排除。
- 2. 调整后的模型完成40/40 steps，Chosen reward 上升、Rejected reward 下降。
- 3. 调整后的模型达到独立开发集上的全部选择阈值。
- 4. 合并模型离线加载和无害生成 smoke 均通过。
- 5. 最终测试集的安全拒绝为10/10，业务题均分为 3.640。

最终 adapter SHA-256 为 d7a932ee4f28c8950db289126381f5d4dd30a037b238852e87ad8e5a241f9e52，merged manifest SHA-256 为 aca9a2932ed427f8fc6e9962e70274eb286a09c446d177af2bc00f6df1675e4c。完整 lineage 见 Final\_DPO\_Model\_Archive.json。

模型权重约 15.2GB，单独存放于模型归档目录。实验记录保存模型路径、文件清单、大小、哈希、加载验证和训练血缘，用于定位模型并核对其完整性。




图3 第4周最终纠偏 DPO 的 Rewards 曲线

图3展示最终40步DPO模型的训练与验证奖励。初始240步实验的Rejected reward呈不同趋势，其日志单独保留用于比较。

## 第5章多模态与 Agent 实践

### 5.1 模型、环境与图片素材

- 模型：Qwen2-VL-7B-Instruct，使用不可变 revision。
- 硬件：NVIDIA GeForce RTX 3090 24 GB。
- Day 22：5 张素材覆盖自然场景、表格、Logo、手写公式和 UI；每张均保存来源、许可、SHA-256 与 ground truth。
- 归档范围：代码仓库保存配置、清单和实验记录；7B 基座权重、LoRA 权重与 checkpoint 单独存储，平台凭据不纳入仓库。

### 5.2 25 条图文推理结果

Day 23 使用 5 张图片 × 5 种问题形成 25 条固定矩阵，25/25 推理成功并完成人工复核。模型对明显自然场景、简单 OCR 和 UI 主体识别表现较好，对小字、精确数值、复杂公式以及严格格式约束较弱。两条记录达到固定 token 上限，在能力边界中作为失败模式保留。

5.3 跨模态注意力方法与热力图

Day 24 固定使用第 20 层 self-attention，对目标文本 token 的前一个 causal prediction row 取视觉 token 权重，对 head 求均值并依据 merger 后的二维网格重排。实验生成 4 张热力图，并保存 per-head、per-token 和 mean attention 数组。热力图只反映固定层与聚合规则下的关注分布，不等同于因果解释。

5.4 十题视觉幻觉检测

Day 25 固定 10 题, 10/10 有原始回答和二元审查; 严格标注的幻觉数为 7, 幻觉率为 7/10=70%。主要问题包括虚构小字、错读公式符号和在图中信息不足时仍给出确定断言。该比例是固定小样本的描述性结果，不外推到所有图像任务。

5.5 数据与 VLM LoRA 训练

Day 26 首轮包含 200 条训练样本、20 条开发样本和 20 条最终样本，并完成图片 SHA 隔离、数据 schema 验证和训练血缘绑定。Day 27 从已审计的 200 条生成一组确定性改写，得到 400 条类别均衡纠偏数据，每类 80 条，与 v8 开发集无图片和 Prompt 交叉。

两个候选都冻结视觉塔与多模态 projector，只训练语言模型的 rank-16 LoRA：

- v8-E：从 v7-B adapter 续训，LR 2e-6，0.5 epoch，50 step，训练成功。
- v8-F：从 Base 重启，LR 1e-5，1.0 epoch，100 step，训练成功。

5.6 Base/LoRA 隔离盲评

开发集选择标准在看到结果前固定：均分增益  $\geq 0.35/5$ 、直接题增益  $\geq 0$ 、Base 未满分的机会题胜率  $\geq 50\%$ 、幻觉率不更差。每个候选都使用同一 20 题和生成配置，在 A/B 身份揭盲前完成五维评分。

表 13 Base/LoRA 隔离盲评

| 指标            | v8-E        | v8-F        | 选择阈值             |
|---------------|-------------|-------------|------------------|
| Base 均分       | 3.9775      | 3.9775      | -                |
| LoRA 均分       | 3.4075      | 3.5250      | -                |
| 均分增益          | -0.5700     | -0.4525     | $\geq 0.3500$    |
| 直接题增益         | -0.2600     | -0.0250     | $\geq 0$         |
| 机会题胜率         | 3/12=25.00% | 4/12=33.33% | $\geq 50\%$      |
| Base/LoRA 幻觉率 | 40% / 60%   | 40% / 55%   | LoRA $\leq$ Base |
| 结论            | FAIL        | FAIL        | 四项全部通过           |

按预注册停止规则，两个开发集候选失败后不再开第三组，不采集新最终集，也不运行最终测试。

5.7 失败、限制与后续改进

本组数据、Base revision、父 adapter、新 adapter、生成配置与每次 run spec 均通过 SHA-256 关联，检查未发现文件同步异常。结果表现为图表类局部改善，而公式、UI、OCR 和指令约束整体退化。小样本训练对输出风格和错误模式的放大是可能解释，但尚无消融实验确定原因。后续可增加经人工核对的高质量样本，减少同图改写占比，并先通过小模型或离线教师模型评分分析数据收益。

5.8 最终模型归档与复现入口

候选模型均未达到全部预设质量阈值。归档保留历史开发集结果最好的 v7-B Base 与 adapter，用于复现和后续比较；其开发集均分增益为 +0.2425，直接题增益为 -0.135，仍低于选择标准。详细路径、Base revision、adapter SHA、数据与配置 SHA 及加载记录见 source/results/final\_vlm\_model\_manifest.json。




图 4 第 20 层目标文字对图像区域的注意力分布

图 4 展示第 5 周场景案例的注意力分布。权重取自 Qwen2-VL 的 self-attention 中目标文本位置对视觉 token 区域的注意力；该实现未使用独立的 cross-attention 模块。

5.9 Agent 工具与端到端表现

环境与模型血缘

表 14 环境与模型血缘

| 项目                            | 记录                                                                             |
|-------------------------------|--------------------------------------------------------------------------------|
| 基座                            | 已核验的 Week4 DPO merged model                                                    |
| SFT 框架                        | LLaMA-Factory 0.9.3                                                            |
| 训练规模                          | 300 train / 40 dev / 100 final test                                            |
| 训练过程                          | 2 epoch / 76 steps / exit code 0                                               |
| 最终 eval loss                  | 0.0638269                                                                      |
| 最终候选                          | checkpoint-38                                                                  |
| checkpoint-38 adapter SHA-256 | a5e348ad180f8183479d3138b40613ead7163f3b2089c9b271063b64be5cdc5c               |
| Prompt                        | main, SHA-256 c16614bb753cd8c5226efde24a5ab1acfc55900023eb6f69679ec047d25f5735 |
| 推理                            | do_sample=false, max_new_tokens=384, seed=42, 最大 6 步                           |

模型、数据、Prompt、知识库和生成配置在最终测试前写入 v2\_frozen\_release.json。最终测试不参与 checkpoint 或 Prompt 选择。

三个工具

表 15 三个工具

| 工具                 | 功能                  | 安全边界                                          |
|--------------------|---------------------|-----------------------------------------------|
| Calculator         | 受限数值表达式计算           | AST 白名单；不调用 eval；限制节点、深度、指数和数值范围              |
| KnowledgeRetrieval | 查询固定本地产品知识库         | 不联网；返回明确的success/not_found/ambiguous/error 状态 |
| CodeExecutor       | Python 语法与风险 AST 检查 | 只解析、不执行代码；测试验证无副作用文件                          |

三工具拥有固定名称、描述和 JSON schema，并在 Agent 初始化时联合绑定。工具返回统一包含 status、data 和 error\_code，便于 Agent 与评测器稳定处理。

ReAct Agent 与单轮调用

Day29 将 Week4 模型接入 ReAct Agent。单轮正式轨迹证明模型能够选择 Calculator、生成合法参数、读取工具返回的 Observation 并输出最终回答。运行记录同时保存模型身份、Prompt、工具 schema 和生成参数。

ReAct 表示“思考—行动—观察—回答”的交替过程。本项目只保存简短路由理由和可审计工具轨迹，不依赖不可复核的长推理文本。

多步任务

Day30 采用包含三个阶段的业务案例：

1. KnowledgeRetrieval 查询商品价格、运费与库存；
2. Calculator 根据检索结果计算总价 719 元；
3. Agent 基于两次工具 Observation 给出购买结论。

同日加入 AST-only CodeExecutor，使工具总数达到 3。复杂任务的 trace、run spec、知识库 SHA 和代码安全审计均保存在实验归档中。

工具调用 SFT

训练数据采用 LLaMA-Factory ShareGPT 工具角色，保留 human→function\_call→observation →gpt 的完整轨迹。数据包含 100 条核心样本和 200 条扩展样本；扩展部分覆盖更多实体、表达式、多步组合、格式与错误终止情形。

训练 loss 从早期约 1.2 下降到后期约 0.05–0.08，四次开发集评测分别对应checkpoint-19/38/57/76。checkpoint-38 的严格成功率 45% 和语义正确率 50% 为四者最高，因此依据开发集任务指标选为最终候选。

固定评测与错误模式

最终测试结果

表 16 最终测试结果

| 指标              | Raw    | Guarded |
|-----------------|--------|---------|
| 严格成功率           | 39.0%  | 27.0%   |
| 首工具选择           | 91.0%  | 91.0%   |
| 完整工具序列          | 91.0%  | 91.0%   |
| 参数 schema 合法    | 100.0% | 100.0%  |
| 参数正确率           | 89.0%  | 89.0%   |
| Observation 完整性 | 100.0% | 100.0%  |
| 格式合法            | 84.0%  | 84.0%   |
| 语义正确率           | 49.0%  | 49.0%   |
| 最终回答可溯源         | 40.0%  | 40.0%   |
| 安全终止            | 95.0%  | 95.0%   |
| 完成率             | 84.0%  | 57.0%   |
| 无循环             | 100.0% | 100.0%  |

Raw 表示模型直接输出的评测结果；Guarded 同时反映安全策略对不允许轨迹的拒绝行为。安全策略没有改变工具路由、参数和语义指标，但降低了系统完成率。

Day32 Prompt 消融

main Prompt 在 40 条开发集上严格通过 18 条，input-fidelity ablation 通过 14 条。主要错误是最终回答语义或可溯源失败，其次是工具调用格式问题；选错工具和参数错误以次要标签出现，死循环为 0。ablation 有 1 条改善、5 条回归，因此最终采用 main Prompt。

安全边界与限制

- CodeExecutor 仅做 AST 静态检查，不执行任意代码；
- Calculator 使用受限解析器，不接受任意 Python；
- KnowledgeRetrieval 只读取固定本地 JSON；
- Agent 设置最大步骤、循环检测、结构化参数校验和安全终止；
- Guarded 结果与 raw 指标分栏报告；
- 代码与结果归档不包含大模型权重、checkpoint、缓存、凭据或平台运维记录。

当前主要能力限制是最终答案与 Observation 的语义对齐。工具路由正确率达到 91%，而端到端严格成功率为 39%，表明最终回答生成仍是主要瓶颈。后续应优先使用结构化解码、最终答案校验和针对 Observation-to-answer 的监督数据。

第 6 章部署与量化

6.1 方法

输入为同一 Week4 corrective merged DPO 模型；原归档为 BF16，FP16 基线显式以 float16 加载，不覆盖原权重。AWQ 和 GPTQ 均为 4-bit、group size 128，实际使用相同 128×1024 token 校准窗口。

同一 RTX3090、共同隔离测量环境、固定评测数据，三个进程顺序运行。每模型 3 次预热、10 次正式生成；输入 512 token，强制输出 128 token，greedy、CUDA 同步计时。吞吐包含 prefill。PPL 采用 256×512 窗口，每模型计分 130816 token，包含全部角色内容，校准源记录及规范化问题与评测互斥。

共同环境使用 torch 2.6.0+cu126、Transformers 4.51.3 和 NumPy 2.2.6。量化工具为 AutoAWQ 0.2.9、Optimum 1.24.0 与 GPTQModel 2.0.0。AWQ 使用未融合 GEMM，GPTQ 使用 TorchQuantLinear，不代表优化服务内核的性能上限。

6.2 结果

表 17 结果

| 模型   | 峰值显存 MiB | 显存下降     | tokens/s | PPL     |
|------|----------|----------|----------|---------|
| FP16 | 17622    | 基准       | 41.2438  | 7.55026 |
| AWQ  | 8286     | 52.9792% | 22.4332  | 8.18261 |
| GPTQ | 8290     | 52.9565% | 20.8910  | 8.02914 |

两种量化的显存均降低约 53%，超过预设的 30% 显存降幅阈值，但本协议下速度下降、PPL 上升。AWQ/GPTQ 的 PPL 相对 FP16 增加约 8.38%/6.34%。显存是 nvidia-smi 进程采样峰值，覆盖加载/预热/生成、不含 PPL 阶段，可能遗漏瞬时峰值；不是显卡总占用或 torch reserved。权重字节数不含tokenizer/config，故小于完整模型文件夹大小。

### 6.3 工具偏差与结论

LLaMA-Factory 0.9.3 的已检查导出分支未能按所用参数完成 AWQ 导出，因此 AWQ 使用 AutoAWQ 0.2.9。GPTQ 使用Optimum/GPTQModel 隔离入口，以处理所选版本之间的 NumPy 依赖冲突；两种量化的实际工具链分别记录。

AWQ 和 GPTQ 原始 v2 均完成新进程重载与短生成验证。本表仅采用完整同口径 v2 结果；早期 v1 的环境一致性证据不足，未采用。量化与部署成功不代表历史训练质量已经恢复。GPTQ 保留 v1 在默认加载路径有零点格式兼容问题，本报告使用可工作的原始 v2。

### 6.4 部署配置概述

部署使用量化后的 Week4 DPO 文本模型，完成FP16/AWQ/GPTQ 对比，搭建 vLLM 兼容 API 和 Gradio 图文应用。文字使用 AWQ 模型，图片使用 Week5 Qwen2-VL-7B-Instruct 基座，两个后端分别承担文本与视觉任务。

### 6.5 量化与测量

完成 AWQ 与 GPTQ 原始 v2 导出、新进程重载和生成验证。AWQ/GPTQ 显存峰值比 FP16 分别下降 52.98%/52.96%；本次冻结协议下速度下降，PPL 分别增加约 8.38%/6.34%，反映出本协议下显存、速度与语言建模损失之间的权衡。完整方法和三路表见量化对比报告。

AWQ 模型单独归档，共 11 个文件、5,586,769,757 字节，包含分词器、配置、索引和全部分片，复制前后 SHA-256 一致。GPTQ 的 Day35 实验保留对比结果与模型位置记录，其完整权重未打包到本地结果归档。

### 6.6 服务与应用

vLLM 以 week4-dpo-quantized 提供同步/流式chat/completions 接口，Python 客户端支持命令行调用。Gradio 支持输入、历史、Temperature/Top-p/输出长度和流式展示；图片页签接入 week5-qwen2-vl-base。

GPU 环境中完成了文字两轮、场景图问答、截断提示、停止后重试、清空换图验证；代码回归 113 项通过。演示视频和优化记录保存在对应实验目录。单卡服务顺序运行，界面标签不会自动切换后端。已验证环境与启动顺序见本地部署与操作手册。

## 6.7 工具路线偏差

实际工具链为 AutoAWQ 0.2.9 及 Optimum 1.24.0/GPTQModel 2.0.0。LLaMA-Factory 0.9.3 的导出分支与所用参数存在兼容性限制，GPTQ 路径另有版本依赖冲突，因此未采用 LLaMA-Factory 的 `export_model` 路径。复现时需要使用上述已验证的隔离环境。

## 6.8 未解决问题

部署可用不等于历史训练模型质量改善。文字仍是归档 DPO 量化版，探索性 SFT 未被选为部署候选。视觉为 Week5 基座，表格错位、公式转写和细节识别不足仍存在，尚未观察到稳定的质量改善。首个输出前立即停止等边界仍需后续验证。

## 6.9 部署验证结果

两种量化格式的显存峰值均降低 30% 以上；vLLM 响应与 Gradio 流式交互经过实际运行验证。对应的环境配置、操作手册、代码、录屏和 AWQ 文件清单共同记录部署过程。服务可用性与模型回答质量分别评价。

# 第 7 章全链路自动化

## 7.1 从实验目录到可重复执行的接口

各阶段配置、脚本、图表和报告按实验日期归档；统一流水线通过显式数据路径、模型路径和版本记录调用各阶段入口。原始实验目录保留历史记录，`scripts` 目录提供可重复执行的接口。

流水线按数据、训练、评估、部署四个阶段执行。数据阶段接收已有归档或用户提供的 JSON 及 JSONL，将清洗、去重、格式转换和划分放在同一可记录过程中。训练阶段读取已经完成对比实验的配置，依次执行 SFT、权重合并、DPO 和再次合并。评估阶段接收合并后的模型路径，先完成公开基准，再生成固定自定义题目并形成多维评分。部署阶段接收经过量化和身份核验的发布模型，以健康检查确认服务已经启动。



图 5 全链路自动化执行顺序

## 7.2 数据阶段的本地验证结果

早期流水线验证使用 5000 条归档样本，正式训练另使用审核后的 1580 条数据。2026 年 9 月 14 日，在独立 Python 环境中使用 Transformers 4.50.0 和本地 Qwen tokenizer 重新处理 Day6 样本，

保留 4999 条并删除 1 条精确重复，模糊去重未新增删除。按问题组划分后，训练集 4499 条、验证集 500 条，问题交集为零，最长完整训练模板为 2048 token。输入、输出哈希和处理模式记录于 data\_statistics.json。

划分前先完成去重，能够避免重复样本同时出现在训练和验证中。相同问题即使有不同回答，也被视为同一个问题组并保持在同一侧。组的顺序由固定随机种子控制，再按九比一随机划分。由于记录数量和组大小是整数，不能保证每种数据的条数都恰好为百分之九十；因此报告同时给出目标规则与实际计数。两种格式保留同一 sample\_id，便于逐行追踪转换关系。

HTML 与控制字符清理处理结构噪声，SimHash 与 Jaccard 识别近重复，token 长度约束控制输入预算。这些检查不验证答案的事实正确性；事实错误、过时知识和回答风格仍需通过语义审查与人工抽查评估。恢复实验中，数据加载成功与生成质量不足同时存在，说明结构验证与内容质量评估承担不同职责。

### 7.3 训练编排与失败语义

SFT 配置来自第三周实选 epoch-e5，其 rank 为 8、alpha 为 16、学习率为 0.0001、训练五轮、随机种子 42。DPO 配置来自第四周最终四十步纠偏实验，保留 beta 为 0.1、较低学习率和原有 warmup 策略。本次新增九比一验证划分，使训练样本数与历史 4999 条全量训练不同。由于训练数据发生变化，历史模型分数仅作参考，新权重单独评估。

每次尝试单独保存配置和日志。遇到显存不足时，程序有限次降低 micro-batch，并相应增加梯度累积，以维持有效 batch；非显存错误直接退出。如果 batch 已经为一仍不足，程序停止并保留失败记录，避免悄悄缩短上下文或减少训练轮数而改变实验含义。训练退出码为零后还检查 adapter 是否存在，导出后检查模型配置与权重文件，防止只依据进程结束就记录完成。

第八周在 320 机完成 SFT 1775 步和 DPO 40 步、两次合并及新进程独立加载。正式输入为审核后的 1580 条，固定拆分为 1422 条训练和 158 条验证；历史 83 条验证数据继续隔离。第四周 DPO 模型与第七周量化模型作为独立的历史模型版本保留，各版本通过清单、哈希和加载记录关联。

### 7.4 自动评估与人工评分协议

公开基准采用 OpenCompass0.5.3 接口，要求 CEval 的 52 个学科、CMMLU 的 67 个学科均产生有效结果及逐题 details，再按题目数加权汇总。缺失科目或异常分数会导致任务失败，不自动填零，也不只挑成功的科目平均。公开选择题主要衡量当前提示、生成和答案提取协议下的表现，仍需与开放题质量结合解释。

自定义题集沿用第三周冻结的二十题。模型输出后交由显式配置的独立裁判接口，按准确性、完整性、逻辑性、安全性、格式五维给出零到五分及具体依据，权重依次为百分之三十、二十五、二十、十五和十。程序检查评分缺项、非有限值和越界值，并保存裁判原始请求与响应，以便复核。候选答案作为数据字段传入裁判，评估器按固定评分协议处理，以降低答案文本干扰评分指令的风险。

模型裁判可能受回答长度和文风影响。人工评分、模型自动评分和确定性检查采用不同评价机制，分别统计和报告。仓库的 quick 模式重新计算历史 OpenCompass 及人工汇总结果，用于验

证文件解析和加权公式；该模式不加载模型，`fresh_model_inference` 为 `false`，其验证范围仅限归档结果回放。

## 7.5 部署生命周期与可复现性

新部署入口复用第七周最终文本服务与图文 UI 代码。监督进程先确认目标端口空闲，再启动 `vLLM`，检查 `health` 和服务模型名称，随后启动 `Gradio` 并检查页面响应。两项都通过才返回 `ready`。启动失败时只清理本次创建的子进程，避免误停其他任务。服务正常后台运行后保留监督进程，收到终止信号时负责回收其子进程。

单张 3090 采用顺序运行文字和视觉服务的策略。图文 UI 拥有两个页签，但页签切换并不等于后端模型自动切换。模型服务、UI 和训练需要不同依赖环境，尤其第七周文字与视觉后端的 `Transformers` 版本不同，因此分别维护独立环境。基础 `environment.yml` 用于 `quick` 入口验证；正式评估、训练与部署分别提供依赖清单，已验证范围见本章环境验证记录。

## 7.6 第八周监督部署实测

320 实测直接调用 `step4_deploy.sh`，加载第 7 周已核验的 Week4 DPO AWQ 4-bit 资产。`vLLM` 健康检查、唯一服务模型身份和 API 生成回答均通过；`Gradio` 首页与队列接口可用，客户端对话经后端调用 `vLLM` 返回完整回答。本次验证覆盖 API 与客户端调用，未覆盖浏览器按钮操作和视觉布局；图片后端未启动，服务仅绑定 127.0.0.1。

首次正常停止后立即重启，发现端口预检对 `TCP TIME_WAIT` 状态误报地址占用。修复仅为预检套接字设置 `SO_REUSEADDR`；正在监听的端口仍被拒绝。套接字测试在修复前复现失败、修复后通过。随后重新完成正常停止、立即重启和主动结束 `Gradio` 子进程三项验证：监督器正确记录状态并回收 `vLLM`，两个端口关闭，GPU 空闲。

部署验证中的 11 项本地测试及 2 项远端套接字测试通过，48 份证据回收核验，保留首次失败记录。量化权重与依赖清单前后不变，验证后关闭实例。结果支持该环境中的服务生命周期管理能力；模型回答质量另行评测，服务未持续公开运行。

## 7.7 评分恢复与主控入口

主控新增 `-score-only` 分支，在数据准备之前进入已冻结的 Gemini 评分恢复流程。默认只离线核验已有成绩；三模型各 20 题的请求、原始响应、评分与用量均重新检查，均分保持 3.9775、3.8275、3.8700。报告写入新目录，原评分和防重复调用记录不被修改。

只有显式 `-execute-score` 且选择单个模型时，入口才允许恢复既有执行。已完整的成绩直接核验，不再次调用收费执行器；未知是否已付费的请求、`FAILED_NO_RETRY`、来源或协议改变仍拒绝自动重试。冲突参数和写入受保护证据目录的请求在执行前拒绝。该分支与 `quick`、训练跳过参数及部署参数互斥，执行范围限定为既有评分的恢复与核验。

在无 `pip` 和第三方包的独立 Python 环境中，主控完成三模型离线核验及 SFT 完整成绩的零调用执行路径；203 个评分和 `claim` 文件保持原哈希，相关 39 项测试通过。此过程未启动 GPU 或新增 API 请求，验证范围为既有评分的恢复和一致性核验。新权重仍需独立执行推理与评估。

示例命令如下，每次使用新报告目录：

```
bash run_pipeline.sh --score-only all --run-dir logs/score-audit-001
```

7.8 第八周正式训练与三模型评估

正式 SFT 完成 1775 步，记录训练损失由 1.1983 降至 0.3143；验证损失却从第 1 轮 0.9285 升至最后 1.5658，提示当前训练强度有过拟合风险。DPO 完成 40 步，验证奖励准确率由第 20 步 0.5517 升至第 40 步 0.7126；该训练指标不等于自定义任务质量改善。两个合并模型均完成独立进程 BF16 CUDA 加载，随后进行完整评测。

表 18 第八周正式训练与三模型评估

| 模型  | CEval 准确率 | CMMLU 准确率 | custom20 AI 均分 |
|-----|-----------|-----------|----------------|
| 原基座 | 77.9346%  | 79.8308%  | 3.9775/5       |
| SFT | 79.6434%  | 79.9516%  | 3.8275/5       |
| DPO | 80.0149%  | 79.9862%  | 3.8700/5       |

每模型 CEval 覆盖 52 科 1346 题，CMMLU 覆盖 67 科 11582 题；分数按题数加权。Gemini 使用同一冻结评分协议，三组各 20 题全部复核，原始回答与请求响应保留。SFT/DPO 新评分 40 次调用、零重试、153932 token；裁判为 gemini-3.1-pro-preview，high 思考、16384 输出上限。该表采用模型自动评分；同批回答的人工评分另见下一节。

SFT 与 DPO 有 12 条完全相同回答，其中 7 条 AI 评分不同，最大差 0.8 分。同文评分波动对总均分差贡献 +0.075，大于 DPO 相对 SFT 总差 +0.0425。该差值尚不足以区分模型效果与裁判评分波动。

固定题的数值末值匹配为原基座4/7、SFT 和 DPO 各2/7；排除 MATH-05 歧义题后分别4/6、2/6、2/6。代码在本机无网络隔离容器运行冻结断言，整题通过分别3/6、1/6、1/6。SFT/DPO 出现缺失函数体、遗漏导入、输入原地修改和异常处理错误，DPO 拓扑排序还存在不移除队首的循环缺陷。数值检查不验证推导，关键词匹配不等于语义正确，代码整题失败也不表示所有断言都失败。

公开选择题基准有所改善，但固定数学与代码任务仍有明显缺陷，现有证据不足以支持全面提升或扩大部署范围。两份各 60 条匿名人工评分见下节。这 20 道题已用于结果分析；后续训练调整需要独立开发集，并另设未参与调参的最终测试集。

证据索引：docs/week8\_acceptance\_audit.md；正式评估汇总：reports/week8/current\_evaluation\_summary.csv；原始回执：phase2\_trained\_generation/generation\_verification.json 及三个 phase2\_gemini\_score 目录的 verification.json；代码诊断：phase2\_custom20\_review/code\_execution.json。

7.9 第八周匿名人工评分结果

评分日期为 2026 年 9 月 18 日，评审仅使用 reviewer\_1 与 reviewer\_2 匿名代号。两份表各 60 条，600 个维度分数均合法、理由完整，题目及回答原文未变。按五维权重30/25/20/15/10 计算，每模型对 20 题和两份评分共 40 条加权分取平均。

表 19 第八周匿名人工评分结果

| 模型  | 准确性   | 完整性   | 逻辑性   | 安全性   | 格式    | 人工均分    |
|-----|-------|-------|-------|-------|-------|---------|
| 原基座 | 3.500 | 4.200 | 3.550 | 4.800 | 4.525 | 3.98250 |
| SFT | 3.100 | 3.725 | 2.925 | 4.750 | 4.900 | 3.64875 |
| DPO | 3.025 | 3.775 | 2.900 | 4.750 | 4.850 | 3.62875 |



图 6 第八周三模型匿名人工五维评分

本 20 题集人工最高均分为原基座。SFT 与 DPO 的均分差为 0.02 分，该差值的稳定性尚未经重复评估验证。去掉有歧义的 MATH-05 后，均分依次为 4.02500、3.70263、3.64737，排序不变；这项敏感性分析不替换 20 题主结果。

每位评审对问题相同回答的五维分数一致。两位评审逐题加权分的平均绝对差分别为原基座 0.135、SFT 0.1875、DPO 0.1925。按事后诊断条件“加权差至少 0.5 或单维差至少 2”标记 10 条分歧用于分析，不排除样本、不改动原分数。人工成绩与 Gemini 结果按评分来源分别统计。数学与代码短板与确定性诊断方向一致；推理类别的变化方向有所不同，表明各类任务的变化并不一致。

人工成绩与证据：reports/week8/phase2\_human\_scores/summary.csv、analysis.json、verification.json 及 review\_metadata.json。评分记录以匿名代号关联。

7.10 流水线入口与依赖验证

现行训练和评估分别由 scripts/pipeline/step2\_train.py 与 scripts/pipeline/step3\_eval.py 承担，主控保留分段执行。训练入口接受冻结正式数据并复用已实测的 5 轮 SFT、40 步 DPO 参数；本次没有重新训练。评估入口使用 OpenCompass 和固定 Gemini 协议，支持 GPU 生成后关闭实例，再在本地完成裁判评分。

在 320 的新代码目录中，正式数据准备产生 1422 条训练与 158 条验证，15 个产物与基准逐字节一致。已有最终 DPO 模型完成每科首题的 119 题基准样本及完整 20 道自定义题；GPU 生成结束后 320 关机，再在本地完成 20 次 Gemini 请求。

表 20 流水线入口与依赖验证

| 入口验证项目   | 结果                | 适用范围          |
|----------|-------------------|---------------|
| C-Eval   | 43/52, 82.6923%   | 每科首题样本        |
| CMMLU    | 54/67, 80.5970%   | 每科首题样本        |
| custom20 | 3.775/5           | 完整 20 题，本次新评分 |
| 生成与依赖核验  | 366 个生成文件、305 个依赖 | 全部核验通过        |

这组样本用于验证评估入口，三模型效果比较仍采用此前各 12928 题的全量成绩。GPU 实测复用既有 Linux CUDA 环境，并非从零安装。

随后在空白 macOS Python3.11 环境安装现行评估依赖；pip check 与 OpenCompass 模型接口导入通过。独立仓库副本在阻止访问原仓库及外网的条件下，完成正式数据 15 文件逐字节复现、119 题评估配置生成、三模型已有评分复核和 6 项入口检查。最新模型评估的答案、依赖及 20 题裁判结果也完成只读核验，新增 API 调用为零。CPU 核验未加载 7B 模型进行新推理。该验证与此前复用 Linux CUDA 环境的 GPU 运行相互独立，尚未覆盖从零安装 CUDA 环境后的全流程运行。

数据与评估安装入口为 configs/requirements-evaluation.txt，训练补充依赖为 configs/requirements-training-cuda.txt。旧 requirements-training.txt 受历史计划哈希绑定，保留原字节作为历史证据，不再作为现行安装入口。部署依赖仍单独维护。

在仓库根目录可依次执行：

```
# 首次安装；Linux GPU 环境须先安装 cu121 版本 torch，详见 configs/README.md
python -m pip install -r configs/requirements-evaluation.txt
python -m pip check

# 正式数据准备
bash run_pipeline.sh --skip-train --skip-eval --run-dir logs/data-001

# 只生成评估计划，不启动模型或 API
EVAL_MODEL_PATH=/absolute/path/final_dpo bash run_pipeline.sh \
    --skip-train --dry-run --eval-limit-per-subject 1 --run-dir logs/eval-plan-001

# 只读核验已归档的最新模型评估，不重复收费
python reports/week8/dependency_delivery_20260919/check_saved_evaluation.py
```

已经完成评分的目录迁移后，付费入口会因原输出路径绑定而拒绝直接重跑；应使用只读核验。尚未开始评分的 GPU 生成目录可以按主 README 流程迁移并首次评分。完整说明见 docs/week8\_dependency\_delivery.md，GPU 运行记录见 reports/week8/delivery\_eval\_20260919/verification.json。

## 第 8 章总结与展望

### 8.1 实验结论与质量限制

本项目贯通了环境配置、原生推理、架构分析、数据清洗、SFT、DPO、多模态理解、工具调用和量化部署。各阶段记录输入、配置、模型版本与评价指标，以支持实验追溯。固定数据和随机种子用于受控比较，独立评估与原始日志用于分析误差，失败候选与成功候选均保留实验记录。

各阶段的质量指标呈现不同变化。第二周三题上微调模型低于基座，第三周最优 SFT 也只是在九个 SFT 候选中最好。第五周两个纠偏候选没有通过明显提升的门槛。第六周工具选择正确率较高，但最终回答与工具 Observation 不一致使完整任务严格成功率只有百分之三十九。第七周量化降低显存，却在当前测量内核下变慢并增加困惑度。这些事实共同提示，损失、路由、压缩率和可交互界面分别反映不同维度，不能互相替代。

### 8.2 补充 SFT 实验分析

九月十一日的探索性 SFT 使用 1580 条训练数据、两轮共 790 步；在相同 83 条验证样本上，token 加权 NLL 由 1.818710 降至 1.372529，下降约百分之二十四点五三。该结果衡量给定参考答案的拟合程度，与生成答案准确率属于不同指标；其中 79 条样本的损失下降。相关文件标记为探索性分析，未达到候选选择标准。

后续检查点诊断比较基座、395 步和 790 步，共形成 180 份回答。部分折扣计算和代码冻结断言出现收益，但加权平均、工程语义和输入不变性仍有错误。代码六题通过原断言，但扩展检查发现输入被修改，表明原断言未覆盖全部行为约束；两套检查结果分别记录。另一次保守一百步 SFT 与基座的严格客观成绩均为 14/24，未观察到整体改善，因此未被选为部署候选。

各次尝试采用独立记录和原始评分。精度路径、数据质量与训练强度可能共同影响结果，其贡献仍需通过配对输入和受控实验分析。文件哈希一致仅验证版本与传输完整性，无法证明数据内容正确；单次推理路径的表现也不足以代表所有训练设置。

### 8.3 知识蒸馏方法与两轮训练

蒸馏实验选择第四周 DPO 模型作为教师模型，Qwen2.5-0.5B-Instruct 作为学生模型。仓库实现采用先离线生成教师模型目标、再训练学生的序列级方法，固定两轮。教师模型生成阶段记录原始回答和截断状态，拒绝空回答及达到预算而未完整结束的目标。学生阶段使用与其自身匹配的 tokenizer 重新清洗、去重和划分，随后进行 LoRA 训练和独立导出。

经典软标签蒸馏可以比较教师模型与学生模型在同一 token 空间上的概率分布；温度较高时分布更平滑，能保留非最大概率类别的信息，KL 项通常乘温度平方以补偿梯度尺度。这里的离线序列目标只保留教师模型生成文本，没有实现逐 token 概率蒸馏，训练目标为生成文本上的监督

损失，未包含软标签 KL 项。配置中的 0.7 仅用于教师模型采样。该取舍减少了同卡同时加载教师模型与学生模型的显存压力，但也丢失教师模型的完整概率分布，并可能继承其错误答案。

本次从正式训练侧抽取 200 条提示生成教师模型目标；200 条全量审核后保留 152 条，排除 9 条截断及 39 条存在问题或核对不充分的回答。152 条按问题组划分为 137 条训练、15 条验证，提示交集为零。该可行性实验将提示规模设为 200 条，学生训练轮数固定为两轮。

学生使用 LoRA rank 8、alpha 16、学习率 0.00005、BF16、长度上限 1024、micro-batch 1、梯度累积 8 和 seed 42。实际完成两轮 36 次优化器更新，共 274 次训练样本呈现。首次与末次记录的批次损失为 1.6044 和 0.6115，这两个值对应日志采样批次，而非完整 epoch 均值；两轮验证损失分别为 1.76046 和 1.75321。168 个 LoRA 模块发生更新，导出后 290 个合并张量通过核验，最终权重在新进程完成 CUDA 冷加载。

## 8.4 蒸馏前后效果与限制

比较在 320 同一块 RTX3090 上进行，两模型均为 0.5B、BF16。CEval 为 52 科 1346 道 val 题，dev 前 5 题作示例，greedy 生成、batch 1、上下文 2048、最多输出 32token。原始与蒸馏模型全部实际提示相同，tokenizer 序列化差异经词表、模板及逐题 token 核验后处理；没有更换评分规则或标准答案。

表 21 蒸馏前后效果与限制

| 指标                   | 原始学生     | 蒸馏学生     | 变化           |
|----------------------|----------|----------|--------------|
| CEval 正确题数           | 723/1346 | 715/1346 | 少 8 题        |
| CEval 准确率            | 53.7147% | 53.1204% | -0.5944 个百分点 |
| 含 prefill 吞吐 token/s | 55.5303  | 55.6263  | +0.1729%     |
| 128token 耗时中位数秒      | 2.300366 | 2.301391 | +0.001026 秒  |

测速使用 12 条固定提示，2 次预热、10 次正式计时，每次恰好生成 128 个新 token；GPU、软件版本和 token 输入一致，并在计时前后同步 CUDA。吞吐微升而耗时中位数微增，只有一次顺序配对，结果表现为速度基本持平，尚无重复测量支持稳定加速。两学生架构相同，LoRA 已合并；本次测速比较同一 0.5B 架构的训练前后版本，未比较 7B 教师模型与 0.5B 学生模型。

两组 707 题都对、615 题都错，8 题由错变对、16 题由对变错。最终选项改变 47 道，其余 23 道由一种错误答案变成另一种错误答案。直接只回答 A/B/C/D 的条数为 1343 和 1345，无法解析为有效选项的条数为 1 和 0；没有证据表明下降来自蒸馏后答题格式恶化。243 份原始预测、评分、配置与回执回收后再次逐题重计分，结果一致。

该次蒸馏未改善 CEval 成绩。仅 137 条训练样本、通用指令与专业知识考试的任务匹配不足，以及教师模型生成答案的信息限制，都是可能影响迁移收益的因素；由于缺少消融和多随机种子实验，8 题净下降的原因及其稳定性尚不确定。当前训练损失下降证明对给定目标的拟合有所改善，不保证 CEval 提升。

本实验完成序列级蒸馏、两轮学生训练及训练前后比较，但未观察到优于原始学生的效果，因此蒸馏模型未被选为替代原始学生的发布候选。详细数据见蒸馏前后比较记录及 phase3\_distillation\_comparison 目录。

## 8.5 可复现性与后续研究

第八周实验包括 SFT 与 DPO 训练、三模型评估、匿名人工评分、两轮学生蒸馏及前后比较，以及监督部署联调。评分恢复已接入主控入口。干净容器中的 quick 回放、独立 Python 环境的评分核验和远端 CUDA 运行分别验证不同环节；目前尚无单个全新 CUDA 环境中一次完成全部流程的运行记录。

最终 SFT、DPO 和蒸馏模型共 38 个文件、约 31.50GB，已完成独立备份、哈希及索引核验，并通过本地 CPU 加载。模型清单将权重文件与训练、合并和评估记录关联，为后续加载与复现提供依据。

后续研究可围绕任务端到端成功率设计数据与评估。文本侧增加复杂约束、工程诊断和输入不变性的监督；视觉侧优先补真实高质量 OCR、表格和公式样本；Agent 侧强化 Observation 到最终答案的证据一致性。超参数对比需要多随机种子、独立最终集以及足够样本量。部署速度则应在相同服务内核和相同请求协议下再测，避免将量化格式的收益与实现内核的差异混为一谈。

综合结果表明，损失收敛、公开基准得分、开放任务质量与部署效率需要分别测量。后续实验可在保留原始输入、配置和输出的基础上，通过独立测试集、重复运行及针对性消融，进一步检验数据质量和训练设置对任务表现的影响。

## 参考资料与证据索引

[1] Qwen2.5 架构分析报告。项目阶段实验记录，2026 年。文件：deliverables/week1/day3/REPORT.md

[2] 第 2 周：数据与 SFT 入门报告。项目阶段实验记录，2026 年。文件：deliverables/week2/day10/REPORT.md

[3] 第 3 周：SFT 优化与评估报告。项目阶段实验记录，2026 年。文件：deliverables/week3/day16/REPORT.md

[4] 第 4 周：DPO 偏好对齐报告。项目阶段实验记录，2026 年。文件：Submission/Week4/Day21\_Weekly\_Report\_and\_Final\_Model\_Archive/Week4\_DPO\_Preference\_Alignment\_Report.md

[5] 第 5 周：多模态实践报告。项目阶段实验记录，2026 年。文件：deliverables/week5/day27/REPORT.md

[6] 第 6 周：Agent 智能体开发报告。项目阶段实验记录，2026 年。文件：deliverables/week6/day33/REPORT.md

[7] FP16 AWQ GPTQ 量化对比报告。项目阶段实验记录，2026 年。文件：Submission/Week7/量化对比报告.md

[8] 第 7 周部署与应用报告。项目阶段实验记录，2026 年。文件：Submission/Week7/第 7 周部署与应用报告.md

[9] OpenCompass 官方快速开始。用于核对 CLI 评估入口。

[10] Transformers 知识蒸馏教程。用于解释软标签、温度与 KL 项，与本项目序列级方法区分。

[11] 正式数据协议: docs/week8\_data\_protocol.md; 冻结协议配置: configs/week8\_data\_protocol.json。

[12] 蒸馏前后比较: docs/week8\_distillation\_comparison.md; 监督部署实测: docs/week8\_supervised\_deployment.md; 主控评分恢复: docs/week8\_pipeline\_score\_integration.md。对应证据分别位于reports/week8 的 phase3\_distillation\_comparison、phase4\_supervised\_deployment 与 phase4\_pipeline\_score\_integration 目录。

[13] 9 月 19 日现行入口模型评估: reports/week8/delivery\_eval\_20260919/verification.json; 依赖与独立副本检查: reports/week8/dependency\_delivery\_20260919/verification.json; 最终模型备份: reports/week8/model\_backup\_20260919/verification.json。